


概率图模型





概率图模型导入





概率建模



例子：基于文本分类是否属于体育运动类新闻

Text	Category
A great game (一个伟大的比赛)	Sports (体育运动)
The election was over (选举结束)	Not sports (不是体育运动)
Very clean match (没内幕的比赛)	Sports (体育运动)
A clean but forgettable game (一场难以忘记的比赛)	Sports (体育运动)
It was a close election (这是一场势均力敌的选举)	Not sports (不是体育运动)



x : 输入词向量的拼接 $x_1 = [x_1^1 \oplus x_1^2 \oplus \dots]$

y : 标签值为0表示“不是体育运动”，
标签值为1表示“体育运动”

最简单的建模方式: $y = w^T x$

概率建模




Text	Category
A great game (一个伟大的比赛)	Sports (体育运动)
The election was over (选举结束)	Not sports (不是体育运动)
Very clean match (没内幕的比赛)	Sports (体育运动)
A clean but forgettable game (一场难以忘记的比赛)	Sports (体育运动)
It was a close election (这是一场势均力敌的选举)	Not sports (不是体育运动)

x : 输入词向量的拼接 $x_1 = [x_1^1 \oplus x_1^2 \oplus \dots]$

y : 标签值为0表示“不是体育运动”，
标签值为1表示“体育运动”

$$y = w^T x \xrightarrow{\text{等价于}} p(y|x) = p(y|x = [x_1^1 \oplus x_1^2 \oplus \dots])$$



概率建模




Text	Category
A great game (一个伟大的比赛)	Sports (体育运动)
The election was over (选举结束)	Not sports (不是体育运动)
Very clean match (没内幕的比赛)	Sports (体育运动)
A clean but forgettable game (一场难以忘记的比赛)	Sports (体育运动)
It was a close election (这是一场势均力敌的选举)	Not sports (不是体育运动)

x : 输入词向量的拼接 $x_1 = [x_1^1 \oplus x_1^2 \oplus \dots]$

y : 标签值为0表示“不是体育运动”，
标签值为1表示“体育运动”


$$y = w^T x \quad \xrightarrow{\text{等价于}} \quad p(y|x) = p(y|x = [x_1^1 \oplus x_1^2 \oplus \dots])$$



概率建模



扁平化
Flattening
..... →



$x = [x^1, x^2, x^3, \dots, x^{N \times N}]$ 高维图像分布

↓
 $z = [z^1, z^2, \dots, z^d]$ d 维隐向量分布

概率建模




Text	Category
A great game (一个伟大的比赛)	Sports (体育运动)
The election was over (选举结束)	Not sports (不是体育运动)
Very clean match (没内幕的比赛)	Sports (体育运动)
A clean but forgettable game (一场难以忘记的比赛)	Sports (体育运动)
It was a close election (这是一场势均力敌的选举)	Not sports (不是体育运动)

x : 输入词向量的拼接 $x_1 = [x_1^1 \oplus x_1^2 \oplus \dots]$

y : 标签值为0表示“不是体育运动”，
标签值为1表示“体育运动”

$$y = w^T x \xrightarrow{\text{等价于}} p(y|x) = p(y|x = [x_1^1 \oplus x_1^2 \oplus \dots])$$




概率建模



导入例子：朴素贝叶斯


Text	Category
A great game (一个伟大的比赛)	Sports (体育运动)
The election was over (选举结束)	Not sports (不是体育运动)
Very clean match (没内幕的比赛)	Sports (体育运动)
A clean but forgettable game (一场难以忘记的比赛)	Sports (体育运动)
It was a close election (这是一场势均力敌的选举)	Not sports (不是体育运动)

如何基于概率建模？



$$p(y|x_1, x_2, x_3)$$

对目标和
可观测变量之间的
关系进行
表示



强假设：输入变量之间相互独立

Bayes Rule:

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$

独立性假设:

$$P(X_1, X_2) = P(X_1)P(X_2)$$

概率建模



导入例子：朴素贝叶斯

Text	Category
A great game (一个伟大的比赛)	Sports (体育运动)
The election was over (选举结束)	Not sports (不是体育运动)
Very clean match (没内幕的比赛)	Sports (体育运动)
A clean but forgettable game (一场难以忘记的比赛)	Sports (体育运动)
It was a close election (这是一场势均力敌的选举)	Not sports (不是体育运动)

如
—

Word	P(word Sports)	P(word Not Sports)
a	$\frac{2 + 1}{11 + 14}$	$\frac{1 + 1}{9 + 14}$
very	$\frac{1 + 1}{11 + 14}$	$\frac{0 + 1}{9 + 14}$
close	$\frac{0 + 1}{11 + 14}$	$\frac{1 + 1}{9 + 14}$
game	$\frac{2 + 1}{11 + 14}$	$\frac{0 + 1}{9 + 14}$

$$p(y|x_1, x_2, x_3) = \frac{p(x_1, x_2, x_3|y)p(y)}{p(x_1, x_2, x_3)} \propto p(x_1, x_2, x_3|y)$$

$$p(x_1, x_2, x_3|y) = p(x_1|y)p(x_2|y)p(x_3|y)$$



在简单数据集中可以直接统计!

概率建模



例子：基于文本分类是否属于体育运动类新闻

Text	Category
A great game (一个伟大的比赛)	Sports (体育运动)
The election was over (选举结束)	Not sports (不是体育运动)
Very clean match (没内幕的比赛)	Sports (体育运动)
A clean but forgettable game (一场难以忘记的比赛)	Sports (体育运动)
It was a close election (这是一场势均力敌的选举)	Not sports (不是体育运动)



最简单的建模方式： $y = w^T x$

如何回答下面的问题？

- 包含“game”这个词的新闻有多少概率属于体育运动类新闻？
- 怎么生成一段属于体育运动类新闻？

概率建模



Text	Category
A great game (一个伟大的比赛)	Sports (体育运动)
The election was over (选举结束)	Not sports (不是体育运动)
Very clean match (没内幕的比赛)	Sports (体育运动)
A clean but forgettable game (一场难以忘记的比赛)	Sports (体育运动)
It was a close election (这是一场势均力敌的选举)	Not sports (不是体育运动)

如何回答下面的问题？

- 包含“game”这个词的新闻有多少概率属于体育运动类新闻？

$$p(y = 1 | x_1 = 'game') \leftarrow ?$$

- 怎么生成一段属于体育运动类新闻？


$$p(x_1, x_2, x_3 | y = 1) \leftarrow ?$$

$$y = w^T x \quad \text{等价于}$$

$$p(y | x_1, x_2, x_3)$$

- 计算难点: $p(y = 1 | x_1 = 'game') = \frac{p(x_1 = 'game' | y = 1)p(y = 1)}{p(x_1 = 'game')}$
- 采样难点: $p(x_1, x_2, x_3 | y = 1) = p(x_1 | y = 1)p(x_2 | y = 1)p(x_3 | y = 1)?$

概率图模型



前馈神经网络为什么长这个样子？



贝叶斯网络


贝叶斯网络(Bayesian network), 又称信念网络(Belief Network), 或有向无环图模型(directed acyclic graphical model), 是一种概率图模型, 于1985年由Judea Pearl首先提出。它是一种模拟人类推理过程中因果关系的不确定性处理模型, 其网络拓扑结构是一个有向无环图(DAG)。

概率图模型




扁平化
Flattening

.....



机变量之间条件



- 每个节点
- 每个连接表示两个随机变量之间具有依赖关系

知参数等


我们先只关注有向图

概率图模型的关键步骤



1. 表示：模型表示（图结构）

Text	Category
A great game (一个伟大的比赛)	Sports (体育运动)
The election was over (选举结束)	Not sports (不是体育运动)
Very clean match (没内幕的比赛)	Sports (体育运动)
A clean but forgettable game (一场难以忘记的比赛)	Sports (体育运动)
It was a close election (这是一场势均力敌的选举)	Not sports (不是体育运动)



2. 学习：Learning

参数学习：给定一组训练样本，求解可观测变量参数


$$p(x_1, x_2, x_3 | y) = p(x_1 | y) p(x_2 | y) p(x_3 | y)$$


3. 推断：Inference

给定可观测变量，推断目标变量的后验概率。


$$p(y | x_1, x_2, x_3) = \frac{p(x_1, x_2, x_3 | y) p(y)}{p(x_1, x_2, x_3)}$$

概率图模型






概率图构建与表示



贝叶斯网络



有向图模型（Directed Graphical model），也称为贝叶斯网络（Bayesian Network），或信念网络



定义 11.1

有向非循环图 G , G 中的每个节点都对应一个随机变量, 每个连接 e_{ij} 表示

$$p(x) = p(x|z, y)p(z, y) = p(x|z)p(z|y)p(y)$$

所有父节点变量求和, $p(x_k|\mathbf{x}_{\pi_k})$ 表示每个随机变量的局部条件概率分布

(Local Conditional Probability Distribution). 如果 $\mathbf{X}$ 的联合概率分布可以分解为每个随机变量 X_k 的局部条件概率的连乘形式, 即

$$p(\mathbf{x}) = \prod_{k=1}^K p(x_k|\mathbf{x}_{\pi_k}), \quad (11.8)$$

那么 $(G, \mathbf{X})$ 构成了一个贝叶斯网络.

局部马尔可夫性质




- 贝叶斯网络的局部马尔可夫性质：每个随机变量在给定父节点的情况下，条件独立于它的非后代节点。



简化，

$$\begin{aligned} p(x) &= p(x|z, y)p(z, y) = p(x|z)p(z|y)p(y) \\ &= p(x_1)p(x_2|x_1)p(x_3|x_1)p(x_4|x_2, x_3), \end{aligned}$$


$P(x)$ 是4个局部条件概率的乘积，这样只需要 $1 + 2 + 2 + 4 = 9$ 个独立参数。




条件独立性




- 在贝叶斯网络中，如果两个节点是直接连接的，它们肯定是非条件独立的，是直接因果关系。
- 父节点是“因”，子节点是“果”。
- 如果两个节点不是直接连接的，但是它们之间有一条经过其他节点的路径连接互连接，它们之间的条件独立性就比较复杂。



练习



$$p(a, b, c) = p(c|a, b)p(a, b) = p(c|a, b)p(b|a)p(a)$$





$$p(x_1, \dots, x_7) = p(x_1)p(x_2)p(x_3)p(x_4|x_1, x_2, x_3) \\ p(x_5|x_1, x_3)p(x_6|x_4)p(x_7|x_4, x_5)$$

图构建




- 如何为一个给定的任务构建概率图？




- 人工经验转换为概率图

Text	Category
A great game (一个伟大的比赛)	Sports (体育运动)
The election was over (选举结束)	Not sports (不是体育运动)
Very clean match (没内幕的比赛)	Sports (体育运动)
A clean but forgettable game (一场难以忘记的比赛)	Sports (体育运动)
It was a close election (这是一场势均力敌的选举)	Not sports (不是体育运动)



- 因果挖掘/概率图结构建模




常见的有向图模型



朴素贝叶斯分类器

给定一个有M维特征的样本 $\mathbf{x}$ 和类别 y ，类别的后验概率为：


$$p(y|\mathbf{x}; \theta) \propto p(y|\theta_c) \prod_{m=1}^M p(x_m|y; \theta_m)$$




Sigmoid信念网络

Sigmoid信念网络网络中的变量为二值变量，取值为 $\{0,1\}$ 。


$$p(x_k = 1|\mathbf{x}_{\pi_k}; \theta) = \sigma(\theta_0 + \sum_{x_i \in \mathbf{x}_{\pi_k}} \theta_i x_i)$$




(a) 只有一层的简单 Sigmoid 信念网络



(b) Logistic 回归模型



基于概率图的参数学习与 模型推断



参数学习



导入例子：朴素贝叶斯

Text	Category
A great game (一个伟大的比赛)	Sports (体育运动)
The election was over (选举结束)	Not sports (不是体育运动)
Very clean match (没内幕的比赛)	Sports (体育运动)
A clean but forgettable game (一场难以忘记的比赛)	Sports (体育运动)
It was a close election (这是一场势均力敌的选举)	Not sports (不是体育运动)

$$p(y|x_1, x_2, x_3) = \frac{p(x_1, x_2, x_3|y)p(y)}{p(x_1, x_2, x_3)} \propto p(x_1, x_2, x_3|y)$$

$$p(x_1, x_2, x_3|y) = p(x_1|y)p(x_2|y)p(x_3|y)$$

在简单数据集中可以直接count!

Word	P(word Sports)	P(word Not Sports)
a	$\frac{2+1}{11+14}$	$\frac{1+1}{9+14}$
very	$\frac{1+1}{11+14}$	$\frac{0+1}{9+14}$
close	$\frac{0+1}{11+14}$	$\frac{1+1}{9+14}$
game	$\frac{2+1}{11+14}$	$\frac{0+1}{9+14}$

能否通过参数估计的形式把上面这张表格估计出来呢？
我们在统计的时候实际就是在做最大似然

参数学习



导入例子：朴素贝叶斯

Text	Category
A great game (一个伟大的比赛)	Sports (体育运动)
The election was over (选举结束)	Not sports (不是体育运动)
Very clean match (没内幕的比赛)	Sports (体育运动)
A clean but forgettable game (一场难以忘记的比赛)	Sports (体育运动)
It was a close election (这是一场势均力敌的选举)	Not sports (不是体育运动)

$$p(y|x_1, x_2, x_3) = \frac{p(x_1, x_2, x_3|y)p(y)}{p(x_1, x_2, x_3)} \propto p(x_1, x_2, x_3|y)$$

$$p(x_1, x_2, x_3|y) = p(x_1|y)p(x_2|y)p(x_3|y)$$



怎么用这个定义来表示整个数据集的概率表示呢？



我们先做如下的参数定义：

定义 $\tilde{X} = (x_1, x_2, \dots, x_N)$, N 表示训练样本的数量

其中, $x_i = (x_i^{(1)}, \dots, x_i^{(n)})^T$

Y 的取值范围为 $C = \{c_1, c_2\}$, $c_k \in \{0, 1\}$

其中变量 $X^{(j)}$ 的取值范围为 $\{w_1, \dots, w_V\}$

定义参数 $\theta_\ell^{c_k}$ 表示词 $p(X^{(j)} = w_\ell | y = c_k)$ 这个概率

参数学习



定义 $\tilde{X} = (x_1, x_2, \dots, x_N)$, N 表示训练样本的数量

其中, $x_i = (x_i^{(1)}, \dots, x_i^{(n)})^T$

Y 的取值范围为 $C = \{c_1, c_2\}$, $c_k \in \{0, 1\}$

其中变量 $X^{(j)}$ 的取值范围为 $\{w_1, \dots, w_V\}$

定义参数 $\theta_\ell^{c_k}$ 表示词 $p(X^{(j)} = w_\ell | y = c_k)$ 即在给定分类的情况下, 句子中出现某个词的概率

$$p(\tilde{X}|Y) = p(\tilde{X}|\Theta) = \prod_{i=1}^N p(x_i|\Theta) \propto \sum_{i=1}^N \log p(x_i|\Theta)$$

$$\mathcal{L} = \sum_{i=1}^N \log p(x_i|\Theta) = \sum_{i=1}^N \sum_{j=1}^n \sum_{k=1}^K \sum_{\ell=1}^V s_{i,j,\ell}^{c_k} \log \theta_\ell^{c_k}$$

其中 $s_{i,j,\ell}^{c_k} \in \{0, 1\}$, 表示句子 i 是否属于当前的类别 c_k 且第 j 个词为 w_ℓ ,

也可以表示成 $s_{i,j,\ell}^{c_k} = I(x_i^{(j)} = w_\ell, y_i = c_k)$ 求解参数 $\theta_\ell^{c_k}$

$$\mathcal{L}' = \sum_{j=1}^n \sum_{k=1}^K \sum_{\ell=1}^V n_{j,\ell}^{c_k} \log \theta_\ell^{c_k} - \lambda \left(\sum_{\ell=1}^V \theta_\ell^{c_k} - 1 \right) \longrightarrow \frac{\partial \mathcal{L}'}{\partial \theta_\ell^{c_k}} = \frac{\partial \mathcal{L}'}{\partial \lambda} = 0$$

其中 $n_{j,\ell}^{c_k} = \sum_{i=1}^N I(x_i^{(j)} = w_\ell, y_i = c_k)$

参数学习



定义 $\tilde{X} = (x_1, x_2, \dots, x_N)$, N 表示训练样本的数量

其中, $x_i = (x_i^{(1)}, \dots, x_i^{(n)})^T$

Y 的取值范围为 $C = \{c_1, c_2\}$, $c_k \in \{0, 1\}$

定义参数 $\theta_\ell^{c_k}$ 表示 $p(x_i^{(n)} = a_\ell | y = c_k)$ 这个概率, ℓ 的取值范围为 $[1, V]$

求解参数 $\theta_\ell^{c_k}$

$$\mathcal{L}' = \sum_{j=1}^n \sum_{k=1}^K \sum_{\ell=1}^V n_{j,\ell}^{c_k} \log \theta_\ell^{c_k} - \lambda \left(\sum_{\ell=1}^V \theta_\ell^{c_k} - 1 \right) \longrightarrow \frac{\partial \mathcal{L}'}{\partial \theta_\ell^{c_k}} = \frac{\partial \mathcal{L}'}{\partial \lambda} = 0$$

其中 $n_{j,\ell}^{c_k} = \sum_{i=1}^N I(x_i^{(j)} = w_\ell, y_i = c_k)$

$$\begin{cases} \sum_{j=1}^n \frac{n_{j,1}^{c_k=0}}{\theta_1^0} - \lambda = 0 \\ \sum_{j=1}^n \frac{n_{j,2}^{c_k=0}}{\theta_2^0} - \lambda = 0 \\ \dots \end{cases}$$

代入

$$\sum_{\ell} \theta_\ell^{c_k} - 1 = 0 \quad \dots$$

$$\theta_1^0 = \frac{\sum_{j=1}^n n_{j,1}^{c_k=0}}{\sum_{\ell=1}^V \sum_{j=1}^n n_{j,1}^{c_k=0}} = \frac{\sum_{j=1}^n \sum_{i=1}^N I(x_i^j = w_1, y_i = 0)}{\sum_{\ell=1}^V \sum_{j=1}^n \sum_{i=1}^N I(x_i^j = w_\ell, y_i = 0)}$$

参数学习



导入例子：朴素贝叶斯

Text	Category
A great game (一个伟大的比赛)	Sports (体育运动)
The election was over (选举结束)	Not sports (不是体育运动)
Very clean match (没内幕的比赛)	Sports (体育运动)
A clean but forgettable game (一场难以忘记的比赛)	Sports (体育运动)
It was a close election (这是一场势均力敌的选举)	Not sports (不是体育运动)

$$p(y|x_1, x_2, x_3) = \frac{p(x_1, x_2, x_3|y)p(y)}{p(x_1, x_2, x_3)} \propto p(x_1, x_2, x_3|y)$$

$$p(x_1, x_2, x_3|y) = p(x_1|y)p(x_2|y)p(x_3|y)$$

在简单数据集中可以直接count!

Word	P(word Sports)	P(word Not Sports)
a	$\frac{2+1}{11+14}$	$\frac{1+1}{9+14}$
very	$\frac{1+1}{11+14}$	$\frac{0+1}{9+14}$
close	$\frac{0+1}{11+14}$	$\frac{1+1}{9+14}$
game	$\frac{2+1}{11+14}$	$\frac{0+1}{9+14}$

分布参数化

$$p(x|y) \rightarrow p_{\theta}(x|y), p(x|y; \theta)$$

$$p(x_1, x_2, x_3|y) = p(x_1|y)p(x_2|y)p(x_3|y) = \prod p_{\theta}(x|y) \propto \sum \log p_{\theta}(x|y)$$

似然函数

参数学习



导入例子：朴素贝叶斯

Text	Category
A great game (一个伟大的比赛)	Sports (体育运动)
The election was over (选举结束)	Not sports (不是体育运动)
Very clean match (没内幕的比赛)	Sports (体育运动)
A clean but forgettable game (一场难以忘记的比赛)	Sports (体育运动)
It was a close election (这是一场势均力敌的选举)	Not sports (不是体育运动)

$$p(y|x_1, x_2, x_3) = \frac{p(x_1, x_2, x_3|y)p(y)}{p(x_1, x_2, x_3)} \propto p(x_1, x_2, x_3|y)$$

$$p(x_1, x_2, x_3|y) = p(x_1|y)p(x_2|y)p(x_3|y)$$

在简单数据集中可以直接count!

Word	P(word Sports)	P(word Not Sports)
a	$\frac{2+1}{11+14}$	$\frac{1+1}{9+14}$
very	$\frac{1+1}{11+14}$	$\frac{0+1}{9+14}$
close	$\frac{0+1}{11+14}$	$\frac{1+1}{9+14}$
game	$\frac{2+1}{11+14}$	$\frac{0+1}{9+14}$

分布参数化

$$p(x|y) \rightarrow p_{\theta}(x|y), p(x|y; \theta)$$

$$p(x_1, x_2, x_3|y) = p(x_1|y)p(x_2|y)p(x_3|y) = \prod p_{\theta}(x|y) \propto \sum \log p_{\theta}(x|y)$$

似然函数

参数学习



$$p(x_1, x_2, x_3|y) = p(x_1|y)p(x_2|y)p(x_3|y) = \prod p_{\theta}(x|y) \propto \sum \log p_{\theta}(x|y)$$

似然函数

最大似然学习:

$$\hat{\theta} = \arg \max \frac{1}{N} \sum \log p_{\theta}(x|y)$$

Word	P(word Sports)	P(word Not Sports)
a	$\frac{2+1}{11+14}$	$\frac{1+1}{9+14}$
very	$\frac{1+1}{11+14}$	$\frac{0+1}{9+14}$
close	$\frac{0+1}{11+14}$	$\frac{1+1}{9+14}$
game	$\frac{2+1}{11+14}$	$\frac{0+1}{9+14}$

$\theta = \{\theta_1, \theta_0\}$, 其中 $\theta_i = N(\mu_i, \sigma_i^2)$

$$p(X_1 = x_1 | y = 1) = \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp\left(-\frac{(x_1 - \mu_1^1)^2}{2\sigma_1^2}\right)$$

参数学习



$$p(x_1, x_2, x_3|y) = p(x_1|y)p(x_2|y)p(x_3|y) = \prod p_{\theta}(x|y) \propto \sum \log p_{\theta}(x|y)$$

似然函数

最大似然学习:

$$\hat{\theta} = \arg \max \frac{1}{N} \sum \log p_{\theta}(x|y)$$

Word	P(word Sports)	P(word Not Sports)
a	$\frac{2+1}{11+14}$	$\frac{1+1}{9+14}$
very	$\frac{1+1}{11+14}$	$\frac{0+1}{9+14}$
close	$\frac{0+1}{11+14}$	$\frac{1+1}{9+14}$
game	$\frac{2+1}{11+14}$	$\frac{0+1}{9+14}$

$\theta = \{\theta_1, \theta_0\}$, 其中 $\theta_i = N(\mu_i, \sigma_i^2)$

$$\mu_{jk} = \frac{1}{N_k} \sum_{i=1}^N x_i^{(j)} I(y_i = c_k)$$

$$\sigma_{jk}^2 = \frac{1}{N_k} \sum_{i=1}^N (x_i^{(j)} - \mu_{jk})^2 I(y_i = c_k)$$

结果推断



给定一个新的样本如何做标签的预测? $(x_1^{test}, x_2^{test}, x_3^{test})$

$$p(y|x_1, x_2, x_3) = \frac{p(x_1, x_2, x_3|y)p(y)}{p(x_1, x_2, x_3)} \propto p(x_1^{test}, x_2^{test}, x_3^{test}|y)$$

简单查表

基于学习的参数进行目标变量的推断


Word	P(word Sports)	P(word Not Sports)
a	$\frac{2+1}{11+14}$	$\frac{1+1}{9+14}$
very	$\frac{1+1}{11+14}$	$\frac{0+1}{9+14}$
close	$\frac{0+1}{11+14}$	$\frac{1+1}{9+14}$
game	$\frac{2+1}{11+14}$	$\frac{0+1}{9+14}$

$$p(X^1 = x_1 | y = 1) = \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp\left(-\frac{(x_1 - \mu_1)^2}{2\sigma_1^2}\right)$$


学习&推断




在以上例子中， x, y 都是可以直接观测到值的变量，当 x, y 等变量无法直接观测时应该怎么办呢？




在这种情况下
要如何建模呢？



基于隐变量的学习和推断




隐变量定义



无法观测变量的分布: $p(z)$

- 图像在生成过程中有一些隐性的影响变量，比如若是拍摄的照片，拍摄氛围、地点等也会影响成像效果。
- 文档在生成的过程中有一些隐形的影响变量，比如特定的主题对文档中用词的影响。
- 我们希望用**隐变量 z** 来代替这些无法观测的情况。

隐变量定义



- 隐变量会如何影响学习和推断过程?
- 隐变量对于可观测变量 x 分布学习的影响:


$$p(x) = \int p(x|y)p(y) dy = \int \int p(x|z)p(z|y)p(y) dz dy$$

- 隐变量对于目标变量 y 分布推断的影响:

$$p(y|x) = \frac{p(x|y)p(y)}{p(x)} = \frac{\int \int p(x|z)p(z|y)p(y) dz}{p(x)}$$

主要都是
积分和条
件分布的
问题?

学习方法



- 如何给出隐变量分布: $p(z)$


- 方法I: 精确推断法

$$p(z) = \sum_x p(z, x)$$

可遍历即可对所有情况都进行计数，
像前面的查表和统计方法

在当前许多任务中都很难应用，因为 z 是高维连续变量

学习方法



- 学习出隐变量的分布参数: $p_{\phi}(z)$

- 近似估计法

本节课程重点中的重点！！

含隐变量的参数学习



- 隐变量即变量是不可观测的



假设参数 z 的分布的参数是 θ

- 点估计：最大似然和最大后验法

$$\hat{\Theta}_{MLE} = \arg \max_{\Theta} p(x | \Theta) \quad \hat{\Theta}_{MAP} = \arg \max_{\Theta} p(\Theta | X, \alpha)$$

需要用EM算法进行参数估计

- 贝叶斯估计：最大化概率期望

$$\begin{aligned} \hat{\Theta}_B &= E_{\Theta \sim p(\Theta | X, \alpha)}[\Theta] \\ &= \int \Theta p(\Theta | X, \alpha) d\Theta \\ &= \int \Theta \left[\frac{p(X | \Theta) p(\Theta | \alpha)}{\int p(X | \Theta) p(\Theta | \alpha) d\Theta} \right] d\Theta \end{aligned}$$

含隐变量的参数学习



- 点估计：最大似然和最大后验法

$$\hat{\Theta}_{MLE} = \arg \max_{\Theta} p(x | \Theta)$$

$$p(\tilde{X}|Y) = p(\tilde{X}|\Theta) = \prod_{i=1}^N p(x_i|\Theta) \propto \sum_{i=1}^N \log p(x_i|\Theta)$$

$$\hat{\Theta}_{MAP} = \arg \max_{\Theta} p(\Theta | X, \alpha)$$

$$P(\Theta|\tilde{X}) = P(\tilde{X}|\Theta)P(\Theta)/P(\tilde{X})$$

$$\log P(\Theta|\tilde{X}) = \log P(\tilde{X}|\Theta) + \log P(\Theta)$$

在参数估计时都是最大似然；
在进行概率值推断的时候，最大后验需要加上参数的先验分布



- MAP 最大后验

- 给定样本和参数的先验分布，求最可能出现的参数

$$\hat{\Theta}_{MAP} = \arg \max_{\Theta} p(\Theta | X, \alpha)$$

- 后验分布：同时考虑观测样本和参数的先验分布

$$\begin{aligned}\hat{\Theta} &= \arg \max_{\Theta} p(\Theta | X, \alpha) \\ &= \arg \max_{\Theta} \frac{p(X | \Theta)p(\Theta | \alpha)}{p(X)} \\ &\propto \arg \max_{\Theta} p(X | \Theta)p(\Theta | \alpha) \\ &= \arg \max_{i=1} \left\{ \underbrace{\sum_{i=1}^n \log p(x_i | \Theta)}_{\text{最大似然}} + \log \underbrace{p(\Theta | \alpha)}_{\text{先验分布}} \right\}\end{aligned}$$

点估计



- 隐变量即变量是不可观测的



假设参数 z 的分布的参数是 θ

- 最大似然法：当不存在隐变量

➤ 直接利用求导为零求解

$$L(x_1, x_2, x_3, \dots, x_N; \Theta) = \prod_{i=1}^N p(x_i | \Theta)$$

$$\ln L(x_1, x_2, x_3, \dots, x_N; \Theta) = \sum_{i=1}^N \ln(p(x_i | \Theta))$$

$$\frac{\partial (\ln L(x_1, x_2, x_3, \dots, x_N; \Theta))}{\partial \Theta} = 0$$

点估计



- 隐变量即变量是不可观测的



假设参数 z 的分布的参数是 θ

现在有两个硬币A和B，这两个硬币投掷朝上朝下的概率都是有偏的，并且两个硬币没有明显的标识。现在要做5组实验，每次实验从两个硬币中随机抽取一个，然后连续抛10次。设参数 θ_A 、 θ_B 分别为硬币A、B正面朝上的概率，求解 θ_A 和 θ_B

	Coin A	Coin B
HTTTHHTHTH	9H, 1T	5H, 5T
HHHHTHHHHH	8H, 2T	
HTHTTTTHHTT	7H, 3T	4H, 6T
THHHTHHHTH	24H, 6T	9H, 11T

5 sets, 10 tosses per set



硬币A和B

AB硬币正面朝上的状态

点估计



- 隐变量即变量是不可观测的



假设参数 z 的分布的参数是 θ

现在有两个硬币A和B，这两个硬币都是有偏的。现在要做5组实验，每次实验从两个硬币中随机抽取一个，然后连续抛10次。设参数 θ_A 、 θ_B 分别为硬币A、B正面朝上的概率，求解 θ_A 和 θ_B



不知道抽中的是哪个硬币

抽硬币



硬币A和B


AB硬币正面朝上的状态

点估计




现在有两个硬币A和B，这两个硬币都是有偏的。现在要做5组实验，每次实验从两个硬币中随机抽取一个，然后连续抛10次。设参数 θ_A 、 θ_B 分别为硬币A、B正面朝上的概率，求解 θ_A 和 θ_B 。

在不知道抽中哪个硬币的情况下就需要用到EM算法



点估计

现在有两个硬币
每次实验从两
、 θ_B 分别为



见在要做5组实验，
10次。设参数 θ_A
和 θ_B

(1) 给 θ_A 、 θ_B 一个初始值 $\theta_A^{(0)} = 0.6$ 、 $\theta_B^{(0)} = 0.5$ ，表示硬币A、B正面朝上概率分别为0.6、0.5；

(2) E步——以第一组实验为例：① 第一组实验结果是5正5反，则硬币A、B抛出5正5反的概率分别为 $pA = C(10, 5) * 0.6^5 * 0.4^5$ 、 $pB = C(10, 5) * 0.5^5 * 0.5^5$ ，那么第一组实验选择的硬币是A的概率为 $\frac{pA}{pA+pB} = 0.449 \simeq 0.45$ ，选择硬币是B的概率为 $1-0.45=0.55$ ；② 若选择的是硬币A，正面朝上次数的期望值为 $0.449 * 5H = 2.2H$ ， $0.449 * 5T = 2.2T$ ，若选择的是B，正面朝上次数的期望值为 $0.551 * 5H = 2.8H$ ， $0.551 * 5T = 2.8T$ ；

(3) M步——利用第三步求得的期望值重新计算 $\theta_A^{(1)} = \frac{2.25}{2.25+4.00}$ ， $\theta_B^{(1)} = \frac{4.00}{4.00+1.00}$ ；

(4) 将参数再带回求解，不断迭代至收敛。



点估计



$$p(x | \Theta) = \int p(x | z)p(z | \Theta)dz$$

• EM算法推导

- 加入隐变量之后的似然

相除

$$\left. \begin{aligned} p(X, z | \Theta) &= \frac{p(X, z, \Theta)}{p(\Theta)} \\ p(z | X, \Theta) &= \frac{p(z, X, \Theta)}{p(X, \Theta)} \end{aligned} \right\} \text{条件概率}$$

$$\frac{p(X, z | \Theta)}{p(z | X, \Theta)} = \frac{\frac{p(X, z, \Theta)}{p(\Theta)}}{\frac{p(z, X, \Theta)}{p(X, \Theta)}} = \frac{p(X, \Theta)}{p(\Theta)} = p(X | \Theta)$$

引入任意分布 $z \sim q(z)$

两边同乘 $q(z)$

$$\begin{aligned} \log p(X | \Theta) &= [\log p(X, z | \Theta) - \log q(z)] - [\log p(z | X, \Theta) - \log q(z)] \\ &= \log \frac{p(X, z | \Theta)}{q(z)} - \log \frac{p(z | X, \Theta)}{q(z)} \end{aligned}$$

$$q(z) \log p(X | \Theta) = q(z) \cdot \log \frac{p(X, z | \Theta)}{q(z)} - q(z) \cdot \log \frac{p(z | X, \Theta)}{q(z)}$$

两边对 $q(z)$ 积分

$$\begin{aligned} \int q(z) \log p(X | \Theta) dz &= \int q(z) \cdot \log \frac{p(X, z | \Theta)}{q(z)} dz - \int q(z) \cdot \log \frac{p(z | X, \Theta)}{q(z)} dz \\ &= \int q(z) \cdot \log \frac{p(X, z | \Theta)}{q(z)} dz + \int q(z) \cdot \log \frac{q(z)}{p(z | X, \Theta)} dz \end{aligned}$$

得到KL散度

对任意 $q(z)$ 左边积分为1

$$\log p(X | \Theta) = \underbrace{E_{z \sim q(z)} \left[\log \frac{p(X, z | \Theta)}{q(z)} \right]}_{\text{Lower Bound } B} + \underbrace{KL[q(z) || p(z | X, \Theta)]}_{\geq 0}$$



$$\log p(x | \Theta) = \underbrace{E_{z \sim q(z)} \left[\log \frac{p(x, z | \Theta)}{q(z)} \right]}_{\text{Lower Bound } B} + \underbrace{KL[q(z) \| p(z | x, \Theta)]}_{\geq 0}$$

- 难点：既需要优化参数，也需要优化分布 $q(z)$

$$B \leftarrow B_{q(z)}(\Theta), KL \leftarrow KL_{\Theta}(q(z))$$

- E步: $\min_{q(z)} KL[q(z) \| p(z | X, \theta)]$
- M步: $\max_{\Theta} B = E_{z \sim q(z)} \left[\log \frac{p(X, z | \Theta)}{q(z)} \right] = E_{z \sim q(z)} [\log p(x | z, \Theta)] - KL[q(z) \| p(z)]$

这个期望怎么算呢？

- 直接采样：

$$E_{z \sim q(z)} [\log p(x|z, \Theta)] = \frac{1}{N} \sum_{z_i} \log p(x|z_i, \Theta)$$

- 变分法（在后面的推断部分会讲到）


收敛性




$$\log p(\mathbf{x}; \theta_{t+1}) \geq \boxed{ELBO(q_{t+1}, \mathbf{x}; \theta_{t+1})} \geq \boxed{ELBO(q_{t+1}, \mathbf{x}; \theta_t)} = \log p(\mathbf{x}; \theta_t)$$

M步


E步



(a) 初始状态



(b) E步更新



(c) M步更新

贝叶斯估计






- 最大化点概率 $\rightarrow$ 最大化概率期望

- $\hat{\theta}_B = E_{\theta \sim p(\theta|X, \alpha)}[\theta]$
 $= \int \theta p(\theta|X, \alpha) d\theta$
 $= \int \theta \left[\frac{p(X|\theta)p(\theta|\alpha)}{\int p(X|\theta)p(\theta|\alpha) d\theta} \right] d\theta$

- 三类情况

- $p(\theta|X, \alpha)$ 可表达, 期望可算: 直接求解
 - $p(\theta|X, \alpha)$ 可表达, 期望不可算: 通过采样模拟或 Variational Inference 求解
 - $p(\theta|X, \alpha)$ 不可表达: Variational Inference 求解



小节





精确推断 Exact Inference

- 变量消去法 (Variable Elimination Algorithm)
- 信念传播
- 联合树算法

近似推断 Approximate Inference

- 变分推断
- 采样法 (蒙特卡罗方法)



关键在于如何计算边际概率。

如何有效地计算边际概率？



- 边际概率

$$p(x_1, x_4) = \sum_{x_2, x_3} p(x_1)p(x_2|x_1)p(x_3|x_1)p(x_4|x_2, x_3)$$

- 如何减少计算量？ 乘法的分配律

$$ab + ac = a(b + c)$$



- 假设要推断的概率分布为 $p(x)$ ，并用来计算期望

$$\mathbb{E}_p[f(x)] = \int_x f(x)p(x)dx.$$

- 采样法

- 也称为蒙特卡罗方法(Monte Carlo Method)
- 数值解：用数值方法求出解，给出一系列对应的自变量和解
- 独立抽取 N 个样本，并计算

$$\bar{f}_N = \frac{1}{N} (f(x^{(1)}) + \dots + f(x^{(N)}))$$

- 根据大数定律，当 N 趋向于无穷大时，样本均值收敛于期望值

采样法



- 直接采样 均匀分布
- 逆变换采样(Inverse Transform Sampling)
- Box–Muller方法 正态分布
- 拒绝采样
- 重要性采样
- 马尔可夫链蒙特卡罗(Markov Chain Monte Carlo, MCMC)方法
 - Metropolis-Hastings算法
 - Metropolis算法
 - Gibbs采样法

拒绝采样



- 假设原始分布 $p(x)$ 难以直接采样，引入一个容易采样的分布 $q(x)$ ，一般称为**提议分布**（Proposal Distribution）


流程：

Step1 从分布 $q(x)$ 中采样

Step2 以某个标准来拒绝一部分的样本

Step3 使得最终采集的样本服从分布 $p(x)$

- 已知一归一化的分布 $\hat{p}(x)$
构建一个提议分布 $q(x)$ 和一个常数 k ，
使得 $kq(x)$ 可以覆盖函数 $\hat{p}(x)$ ，即
 $kq(x) \geq \hat{p}(x), \forall x$



拒绝采样



算法 11.2 拒绝采样的采样过程

输入: 提议分布 $q(x)$, 常数 k , 样本集合 $\mathcal{V} = \emptyset$;

```
1 repeat
2   根据  $q(x)$  随机生成一个样本  $\hat{x}$ ;
3   计算接受概率  $\alpha(\hat{x})$ ;
4   从  $(0, 1)$  的均匀分布中随机生成一个值  $z$ ;
5   if  $z \leq \alpha(\hat{x})$  then                                // 以  $\alpha(\hat{x})$  的概率接受  $\hat{x}$ 
6      $\mathcal{V} = \mathcal{V} \cup \{\hat{x}\}$ ;
7   end
8 until 获得  $N$  个样本 ( $|\mathcal{V}| = N$ );
```

输出: 样本集合 $\mathcal{V}$

$$\alpha(\hat{x}) = \frac{\hat{p}(\hat{x})}{kq(\hat{x})}$$

接受概率 (Acceptance Probability)

重要性采样



- 如果采样的目的是计算分布 $p(x)$ 下函数 $f(x)$ 的期望，那么实际上抽取的样本不需要严格服从分布 $p(x)$ 。也可以通过另一个分布，即提议分布 $q(x)$ ，直接采样并估计 $E_p[f(x)]$ 。

$$\begin{aligned}\mathbb{E}_p[f(x)] &= \int_x f(x)p(x)dx \\ &= \int_x f(x)\frac{p(x)}{q(x)}q(x)dx \\ &= \int_x f(x)w(x)q(x)dx \\ &= \mathbb{E}_q[f(x)w(x)].\end{aligned}$$

$w(x)$ 为重要性权重



$$\hat{f}_N = \frac{1}{N} (f(x^{(1)})w(x^{(1)}) + \dots + f(x^{(N)})w(x^{(N)}))$$

变分推断



$$\begin{aligned} \bullet \text{ E步: } & \min_{q(z)} KL[q(z) \| p(z | X, \theta)] \\ \bullet \text{ M步: } & \max_{\Theta} B = E_{z \sim q(z)} \left[\log \frac{p(X, z | \Theta)}{q(z)} \right] = \boxed{E_{z \sim q(z)} [\log p(x | z, \Theta)]} - KL[q(z) \| p(z)] \end{aligned}$$

- 如何定义 $q(z)$ 并在E步中进行求解?
- 如何处理M step中的积分项?

方法1: MCMC求解

- 思路: 不对后验分布 $p(z|x, \theta)$ 做近似, 而是直接通过数值模拟出期望值, 代入到目标中
- E Step: 直接从后验 $p(z|x, \theta)$ 中采样 L 个样本 $z^{(l)}$
 $q(z) = p(z|x, \theta)$
- M Step: 对积分项采样模拟, 梯度下降更新 θ

$$E_{z \sim q(z)} [\log p(x|z, \theta)] \approx \frac{1}{L} \sum_{l=1}^L \log p(x|z^{(l)}, \theta) \text{ , where } z^{(l)} \sim q(z)$$

变分推断



方法2：变分推断求解

- 思想：对后验分布 $p(z|x, \theta)$ 做近似，然后求解近似分布的参数
- 给分布 $q(z)$ 引入参数 ϕ 得到 $q(z|\phi)$ ，E中优化 ϕ ，M中优化 θ （对于积分项直接数学求解）

1. **E Step**: 通过参数 ϕ 找到一个分布 $q(z|\phi)$ 使得这个分布与 z 的后验分布 $p(z|x, \theta)$ 之间的 KL 散度最小，即：

$$\min_{\phi} KL[q(z|\phi) \| p(z|x, \theta)]$$

后验分布难以求解

2. **M Step**: 基于优化的参数 ϕ 得到似然函数的下界 B ，通过优化参数 θ 从而最大化这个下界，即：

$$\max_{\theta} B = E_{z \sim q(z|\phi)} \left[\log \frac{p(x, z|\theta)}{q(z|\phi)} \right]$$

变分推断



- 变分推断怎么处理棘手的后验分布?

- 原EM优化:

左项, 即B (M Step)

右项 (E Step)

$$\log p(x|\theta) = \underbrace{E_{z \sim q(z|\phi)} [\log p(x|z, \theta)] - KL[q(z|\phi) \| p(z)]}_{\max_{\theta}} + \underbrace{KL[q(z|\phi) \| p(z|x, \theta)]}_{\min_{\phi}}$$

存在关系:

右项 = -左项 + $\log p(x|\theta)$

通过优化 ϕ 增大左项
-> 减小右项

- 新的EM优化方法:

$$\log p(x|\theta) = \underbrace{E_{z \sim q(z|\phi)} [\log p(x|z, \theta)] - KL[q(z|\phi) \| p(z)]}_{\max_{\theta} \max_{\phi}} + KL[q(z|\phi) \| p(z|x, \theta)]$$

通常需要设计合理的 $q(z|\phi)$,
使得积分项可解。

- E Step: 优化参数 ϕ 以最大化左项
- M Step: 代入E Step的 ϕ , 优化参数 θ 以最大化左一项 (左二与 θ 无关)
- EM算法中参数更新的方法为: 求解相应项的导数的零点

缺点:


1. 分布 $q(z|\phi)$ 的设计有时很难
2. 效果易受近似分布形式的影响

变分推断




实例: Variational Auto-Encoder (VAE)

传统AE



Reconstruction Loss


VAE



变分推断




Why Variational Auto-Encoder (VAE)?



变分推断



Why Variational Auto-Encoder (VAE)?



变分推断



$$\log p(x|\theta) = \underbrace{E_{z \sim q(z|\phi)} [\log p(x|z, \theta)] - KL[q(z|\phi) \| p(z)]}_{\max_{\theta} \max_{\phi}} + KL[q(z|\phi) \| p(z|x, \theta)]$$


通常需要设计合理的 $q(z|\phi)$,
使得积分项可解。

- E Step: 优化参数 ϕ 以最大化左项
- M Step: 代入E Step的 ϕ , 优化参数 θ 以最大化左一项 (左二与 θ 无关)
- EM算法中参数更新的方法为: 求解相应项的导数的零点

缺点:

1. 分布 $q(z|\phi)$ 的设计有时很难
2. 效果易受近似分布形式的影响

• VAE概率图模型的设计



- 缩小解空间, 将变分分布设计为 $q(z|x, \phi)$
- 把先验 $p(x|z, \theta)$ 变形为 $p(x|f_{\theta}(z))$
- 把先验 $q(z|x, \phi)$ 变形为 $q(z|g_{\phi}(x))$

$f_{\theta}(\cdot)$ 可看作decoder
 $g_{\phi}(\cdot)$ 可看作encoder




VAE概率图模型的形式

- 在前文的变分推断求解中，最大化似然概率 $\log p(x|\theta)$ 等价于优化下式红框：

$$\log p(x|\theta) = \underbrace{E_{z \sim q(z|\phi)} [\log p(x|z, \theta)] - KL[q(z|\phi) \| p(z)]}_{\max_{\theta} \max_{\phi}} + KL[q(z|\phi) \| p(z|x, \theta)]$$

- VAE的方程：

$$\log \underbrace{p(x|\theta)}_{\text{likelihood}} - KL \left[\underbrace{q(z|g_{\phi}(x))}_{\text{encoder}} \| \underbrace{p(z|x, \theta)}_{\text{posterior}} \right] = \underbrace{E_{q(z|g_{\phi}(x))} [\log p(x|f_{\theta}(z))]}_{\text{decoder}} - KL \left[\underbrace{q(z|g_{\phi}(x))}_{\text{encoder}} \| \underbrace{p(z)}_{\text{prior}} \right]$$



x 为观测变量， z 为隐藏变量，
模型参数为 θ, ϕ

求解目标：为了最大化似然，
通过 θ, ϕ 直接优化右式的下界。



VAE概率图模型的求解

- 优化目标为等号右侧

$$\log \underbrace{p(x|\theta)}_{\text{likelihood}} - KL \left[\underbrace{q(z|g_\phi(x))}_{\text{encoder}} \parallel \underbrace{p(z|x, \theta)}_{\text{posterior}} \right] = \overbrace{E_{q(z|g_\phi(x))} [\log p(x|f_\theta(z))]}^{\mathcal{L}_2(\theta, \phi|x^{(i)})} - \overbrace{KL \left[\underbrace{q(z|g_\phi(x))}_{\text{encoder}} \parallel \underbrace{p(z)}_{\text{prior}} \right]}^{\mathcal{L}_1(\phi|x^{(i)})}$$

- 对于数据点 $x^{(i)}$ ，需最大化“损失函数”，即 $\mathcal{L}(\theta, \phi|x^{(i)}) = \mathcal{L}_1(\phi|x^{(i)}) + \mathcal{L}_2(\theta, \phi|x^{(i)})$

- 更新方式为随机梯度“下降”

$$\{\theta, \phi\} = \{\theta, \phi\} + \lambda \cdot \frac{\mathcal{L}(\theta, \phi|x^{(i)})}{\partial\{\theta, \phi\}}$$

变分推断



- 优化目标为等号右侧

$$\log \underbrace{p(x|\theta)}_{\text{likelihood}} - KL \left[\underbrace{q(z|g_\phi(x))}_{\text{encoder}} \parallel \underbrace{p(z|x, \theta)}_{\text{posterior}} \right] = \underbrace{E_{q(z|g_\phi(x))} [\log p(x|f_\theta(z))]}_{\text{decoder}} - \underbrace{KL [q(z|g_\phi(x)) \parallel p(z)]}_{\text{encoder prior}}$$

reconstruction error $\mathcal{L}_2(\theta, \phi|x^{(i)})$ regularization term $\mathcal{L}_1(\phi|x^{(i)})$

- 对于数据点 $x^{(i)}$ ，需最大化“损失函数”，即 $\mathcal{L}(\theta, \phi|x^{(i)}) = \mathcal{L}_1(\phi|x^{(i)}) + \mathcal{L}_2(\theta, \phi|x^{(i)})$

- 更新方式为随机梯度“下降”：

$$\{\theta, \phi\} = \{\theta, \phi\} + \lambda \cdot \frac{\mathcal{L}(\theta, \phi|x^{(i)})}{\partial \{\theta, \phi\}}$$

- $\mathcal{L}_1$ 项KL散度容易计算（例如假设 $q(z|g_\phi(x))$ 和 $p(z)$ 都是高斯分布），导数也易求得

- 对于 $\mathcal{L}_2$ 项梯度的求解：

- (×) 在变分推断求解中的积分求解，容易受近似分布形式的影响，难度较大
- (×) 在采样求解中的采样+数值模拟，存在效率问题，且采样结果丢失分布的参数信息：

$$\frac{\partial E_{q(z|g_\phi(x))} [\log p(x|f_\theta(z))]}{\partial \phi} \approx \frac{\frac{1}{L} \sum_{l=1}^L \partial \log p(x|f_\theta(z^{(l)}))}{\partial \phi} = 0, \text{ where } z^{(l)} \sim q(z|g_\phi(x)) \quad \Rightarrow \text{reparameterization}$$

$$\begin{aligned} D_{KL}(q(z|x)||p(z)) &= \int q(z|x) \log \frac{q(z|x)}{p(z)} dz \\ &= \int q(z|x) \{ \log q(z|x) - \log p(z) \} dz \\ &= \int q(z|x) \log q(z|x) dz - \int q(z|x) \log p(z) dz \\ &= \left(-\frac{J}{2} \log(2\pi) - \frac{1}{2} \sum_{j=1}^J (\log \sigma_j^2 + 1) \right) - \left(-\frac{J}{2} \log(2\pi) - \frac{1}{2} \sum_{j=1}^J (\sigma_j^2 + \mu_j^2) \right) \\ &= -\frac{1}{2} \sum_{j=1}^J \left(1 + \log \sigma_j^2 - \sigma_j^2 - \mu_j^2 \right) \end{aligned} \quad (5)$$



SGVB求解

$$\mathcal{L}(\theta, \phi | x^{(i)}) = E_{q(z|g_\phi(x))} [\underbrace{\log p(x|f_\theta(z))}_{\text{decoder}}] - \underbrace{KL[q(z|g_\phi(x)) \| p(z)]}_{\text{encoder prior}}$$

$\mathcal{L}_2(\theta, \phi | x^{(i)}) + \mathcal{L}_1(\phi | x^{(i)})$

- 采样丢失了变分分布 $z \sim q(z|g_\phi(x))$ 的参数 ϕ 的梯度，故设计对 z 进行 **reparameterization**:

$$z^{(l)} = \tilde{g}_\phi(\epsilon^{(l)}, x), \text{ where } \epsilon^{(l)} \sim p(\epsilon)$$

- 对于一个微小噪声变量 $\epsilon^{(l)} \sim p(\epsilon)$ ，基于一个确定性的函数 $\tilde{g}_\phi(\epsilon, x)$ 实现与 $z^{(l)}$ 的一一对应
- 把 $z = \tilde{g}_\phi(\epsilon, x)$ 代入目标函数

变分推断



- 采样丢失了变分分布 $z \sim q(z|g_\phi(x))$ 的参数 ϕ 的梯度，故设计对 z 进行 **reparameterization**:

$$z^{(l)} = \tilde{g}_\phi(\epsilon^{(l)}, x), \text{ where } \epsilon^{(l)} \sim p(\epsilon)$$

- 对于一个微小噪声变量 $\epsilon^{(l)} \sim p(\epsilon)$ ，基于一个确定性的函数 $\tilde{g}_\phi(\epsilon, x)$ 实现与 $z^{(l)}$ 的一一对应
- 把 $z = \tilde{g}_\phi(\epsilon, x)$ 代入 $\mathcal{L}_2(\theta, \phi|x^{(i)})$ ，有：

$$\begin{aligned}\mathcal{L}_2(\theta, \phi|x^{(i)}) &= E_{q(z|g_\phi(x))}[\log p(x|f_\theta(z))] \\ &= E_{p(\epsilon)}[\log p(x|f_\theta(\tilde{g}_\phi(\epsilon, x)))] \\ &\approx \frac{1}{L} \sum_l \log p(x|f_\theta(\tilde{g}_\phi(\epsilon^{(l)}, x)))\end{aligned}$$

间接地从 $p(\epsilon)$ 而非 $q(z|g_\phi(x))$ 中采样，原先分布中的参数 ϕ 转移到了期望的内容中。这时数值模拟的 $\mathcal{L}_2$ ，导数可求解。

Algorithm 1 AEVB 对单数据点更新算法

Initialize parameters θ, ϕ

repeat

Draw a datapoint $x^{(i)}$

Draw noise samples $\epsilon^{(l)} \sim p(\epsilon)$

Update θ with:

$$\theta = \theta + \lambda \cdot \frac{1}{L} \sum_{l=1}^L \frac{\partial \log p(x^{(i)}|f_\theta(\tilde{g}_\phi(\epsilon^{(l)}, x^{(i)})))}{\partial \theta}$$

Update ϕ with:

$$\phi = \phi + \lambda \cdot \left[\frac{\partial \mathcal{L}_1(\phi|x^{(i)})}{\partial \phi} + \frac{1}{L} \sum_{l=1}^L \frac{\partial \log p(x^{(i)}|f_\theta(\tilde{g}_\phi(\epsilon^{(l)}, x^{(i)})))}{\partial \phi} \right]$$

until convergence


变分推断




VAE的神经网络实现

$$\mathcal{L}(\theta, \phi | x^{(i)}) \approx \underbrace{\frac{1}{L} \sum_l \log p(x | f_\theta(\tilde{g}_\phi(\epsilon^{(l)}, x)))}_{\text{reconstruction error}} - \underbrace{KL[q(z | g_\phi(x)) || p(z)]}_{\text{regularization term}}$$

- 假设decoder函数的输出 $p(x | f_\theta(x))$ 服从高斯分布，encoder函数的输出 $q(z | g_\phi(x))$ 服从高斯分布，隐变量 z 的先验服从高斯分布
- 基于SGVB，映射函数设计为 $\tilde{g}_\phi(\epsilon, x) = \mu + \sigma \cdot \epsilon$





谢谢！

THANK YOU FOR LISTENING

